

## **Avaliação A2 - Relatório do Trabalho**

## Sumário

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>1. INTRODUÇÃO.....</b>                                    | <b>3</b>  |
| 1.1. Objetivo.....                                           | 3         |
| 1.2. Visão geral dos domínios.....                           | 3         |
| <b>2. METODOLOGIA GERAL.....</b>                             | <b>3</b>  |
| 2.1. Definição do problema e balanceamento.....              | 3         |
| 2.2. Separação treino/validação/teste.....                   | 4         |
| 2.3. Pré-processamento e representação.....                  | 4         |
| 2.4. Algoritmos e ajustes de hiperparâmetros.....            | 4         |
| 2.5. Métricas de avaliação.....                              | 5         |
| 2.6. Explicabilidade dos modelos(Gráfico SHAP beeswarm)..... | 6         |
| 2.7. Programa para criação de histogramas(parte 1).....      | 6         |
| <b>3. BASE 1 - Análise de sentimentos em avaliações.....</b> | <b>7</b>  |
| 3.1. Descrição da base de dados.....                         | 7         |
| 3.2. Balanceamento das classes.....                          | 7         |
| 3.3. Separação dos dados e pré-processamento.....            | 7         |
| 3.4. Comparação dos algoritmos.....                          | 8         |
| 3.5. Avaliação do melhor modelo.....                         | 9         |
| 3.6. Explicabilidade(gráfico beeswarm).....                  | 11        |
| 3.7. Aplicação do programa da parte 1.....                   | 13        |
| <b>4. BASE 2 - Anúncios De Fazenda.....</b>                  | <b>17</b> |
| 4.1. Descrição da base de dados.....                         | 17        |
| 4.2. Balanceamento das classes.....                          | 17        |
| 4.3. Separação dos dados e pré-processamento.....            | 18        |
| 4.4. Comparação dos algoritmos.....                          | 18        |
| 4.5. Avaliação do melhor modelo.....                         | 19        |
| 4.6. Explicabilidade (gráfico beeswarm).....                 | 21        |
| 4.7. Aplicação do programa da parte 1.....                   | 23        |
| <b>5. BASE 3 - Sites de phishing.....</b>                    | <b>26</b> |
| 5.1. Descrição da base de dados.....                         | 26        |
| 5.2. Balanceamento das classes.....                          | 27        |
| 5.3. Separação dos dados e pré-processamento.....            | 28        |
| 5.4. Comparação dos algoritmos.....                          | 28        |
| 5.5. Avaliação do melhor modelo.....                         | 29        |
| 5.6. Explicabilidade(gráfico beeswarm).....                  | 31        |
| 5.7. Aplicação do programa da parte 1.....                   | 33        |
| <b>6. CONCLUSÃO.....</b>                                     | <b>36</b> |
| <b>7. REFERÊNCIAS.....</b>                                   | <b>37</b> |

## 1. INTRODUÇÃO

### 1.1. Objetivo

Este trabalho tem como objetivo desenvolver e avaliar o desempenho de diferentes modelos de aprendizado de máquina, utilizando bases de dados supervisionadas binárias. Além disso, o trabalho propõe o desenvolvimento de um programa reutilizável que cria gráficos no formato de histogramas, para auxiliar na definição de faixas de decisão a partir das probabilidades estimadas pelos modelos.

### 1.2. Visão geral dos domínios

Os três domínios escolhidos foram os seguintes:

| Base de Dados             | Variável alvo            | Classe positiva                      | Classe negativa                      |
|---------------------------|--------------------------|--------------------------------------|--------------------------------------|
| Sentimentos de avaliações | class(positive/negative) | A frase expressa sentimento positivo | A frase expressa sentimento negativo |
| Anúncios de fazenda       | aprovado(1/-1)           | O anúncio foi aprovado               | O anúncio foi reprovado              |
| Sites de phishing         | result(1/-1)             | O site é phishing                    | O site é legítimo                    |

*Tabela 1. Visão geral dos três domínios estudados, definindo Variável alvo e classe positiva e negativa*

## 2. METODOLOGIA GERAL

Esta seção apresenta os conceitos e procedimentos comuns à construção e avaliação dos modelos nos três domínios estudados. As seções de cada base tratam apenas do que é específico dela: origem dos dados, escolha da métrica-alvo, pré-processamento próprio, espaços de busca e resultados.

### 2.1. Definição do problema e balanceamento

Em todos os domínios o problema é de classificação binária supervisionada. A variável-alvo foi codificada como 0 ou 1, em que 1 é a classe positiva e 0 a classe negativa. A quantidade e o percentual de cada classe foram calculados antes de qualquer divisão dos dados.

O balanceamento influencia a escolha das métricas. Em bases muito desbalanceadas, a acurácia engana: um modelo que sempre prevê a classe majoritária já teria acurácia alta. Nesse caso, a precisão, recall e curva Precision-Recall são mais informativas. Além disso, os dois tipos de erro têm um custo diferente dependendo do contexto de construção e avaliação dos modelos da base de dados. Um falso negativo (FN) é um caso positivo que o modelo deixa passar. Um falso positivo (FP) é um caso negativo marcado como positivo. A

métrica-alvo de cada domínio, usada na seleção do modelo, é escolhida conforme o erro mais custoso, e essa justificativa está na seção de cada base.

## **2.2. Separação treino/validação/teste**

Cada base foi dividida em dois conjuntos por amostragem aleatória estratificada, que mantém a proporção de classes em ambos:

- Teste (25%): reservado e usado apenas na avaliação final.
- Treinamento (75%): usado para treinar, ajustar hiperparâmetros, selecionar o modelo e escolher os pontos de corte da Parte 1.

Em vez de um conjunto de validação fixo, usamos validação cruzada estratificada de 5 partições (StratifiedKFold, com embaralhamento) sobre o desenvolvimento. Os dados são divididos em 5 blocos, e cada bloco serve uma vez como validação enquanto os outros 4 treinam o modelo. O resultado de validação é a média das 5 rodadas, o que o torna mais estável do que uma única divisão. As mesmas partições foram usadas para todos os algoritmos, de modo que a comparação entre eles é justa. O teste só é consultado depois que o modelo foi escolhido, e as métricas de teste dos três algoritmos são reportadas para comparação, sem influenciar a seleção.

## **2.3. Pré-processamento e representação**

Os dados brutos foram convertidos em representações numéricas, conforme o tipo de variável:

- Texto (TF-IDF): cada documento vira um vetor em que cada termo tem peso igual ao produto de dois fatores: sua frequência no documento (TF) e o inverso da sua frequência na coleção (IDF). Termos comuns a quase todos os documentos recebem peso baixo, e termos distintivos recebem peso alto.
- Categóricas (One-Hot Encoding): cada categoria vira uma coluna binária (1 se presente, 0 se ausente). Isso evita que o modelo trate códigos como -1, 0 e 1 como uma escala numérica com ordem e distância.

Todas as transformações foram colocadas dentro de um Pipeline do scikit-learn, junto com o classificador. Assim, em cada rodada da validação cruzada, o vocabulário e os pesos IDF (ou as categorias do codificador) são aprendidos só com as partes de treino daquela rodada e depois aplicados à parte de validação. No teste final, usa-se a transformação ajustada no desenvolvimento completo. Isso evita o vazamento de dados (data leakage): se a transformação "enxergasse" dados de validação ou de teste, as métricas ficariam artificialmente otimistas.

## **2.4. Algoritmos e ajustes de hiperparâmetros**

Em cada domínio foram comparados três algoritmos de classificação que estimam a probabilidade da classe positiva, requisito para a Parte 1. Hiperparâmetros são configurações definidas antes do treino, como a profundidade das árvores ou a força de regularização, e não são aprendidos através dos dados.

Para ajustá-los, usamos busca com validação cruzada (RandomizedSearchCV, que sorteia um número fixo de combinações do espaço de busca, ou GridSearchCV, que

testa todas). Cada combinação é avaliada nas 5 partições pela métrica-alvo do domínio. A de maior média é escolhida e o modelo é retreinado com todo o desenvolvimento. O modelo final do domínio é o algoritmo com maior média de validação. Os espaços de busca e o número de combinações de cada algoritmo estão nas seções das bases.

## 2.5. Métricas de avaliação

O desempenho dos modelos foi avaliado a partir da matriz de confusão, que organiza as predições em quatro categorias: verdadeiros positivos (TP), falsos positivos (FP), verdadeiros negativos (TN) e falsos negativos (FN). A partir dela foram calculadas:

- Acurácia:  $(TP + TN) / \text{total de instâncias}$ .
- Precisão:  $TP / (TP + FP)$ , proporção de instâncias classificadas como positivas que de fato são positivas.
- Recall:  $TP / (TP + FN)$ , proporção de instâncias positivas corretamente identificadas.
- F1-score: média harmônica entre precisão e recall, útil quando é preciso equilibrar os dois tipos de erro.

Essas quatro métricas dependem de um limiar de decisão  $T$ , valor de probabilidade a partir do qual uma instância é classificada como positiva; usamos  $T = 0,50$  nos três domínios, o que é reafirmado em cada seção de avaliação.

Para avaliar o modelo independentemente de um limiar específico, utilizamos duas curvas, construídas variando  $T$  de 1 a 0 e recalculando, a cada ponto, um par de indicadores:

- Curva ROC: relaciona a taxa de verdadeiros positivos,  $TPR = \text{recall} = TP/(TP+FN)$ , e a taxa de falsos positivos,  $FPR = FP/(FP+TN)$ . Sua área (AUC-ROC) equivale à probabilidade de o modelo atribuir uma pontuação maior a uma instância positiva do que a uma negativa, escolhidas aleatoriamente; 0,5 indica desempenho aleatório e 1,0 indica separação perfeita entre as classes.
- Curva Precision-Recall: relaciona, para cada limiar, a precisão  $= TP/(TP+FP)$  e o recall. Tende a ser mais informativa que a ROC quando as classes são desbalanceadas, pois não usa TN no cálculo. Diferente da ROC, cuja linha de base é sempre 0,5, a linha de base da curva PR é a própria prevalência de positivos no conjunto avaliado, quanto mais desbalanceada a base, mais essa linha se afasta de 0,5. Sua área (AUC-PR) pode ser calculada por integração trapezoidal dos pontos da curva (liga os pontos por segmentos de reta, o que tende a ser levemente otimista entre pontos discretos) ou pela métrica Average Precision (AP), que soma  $AP = \sum_i (R_i - R_{i-1}) \cdot P_i$ , ponderando a precisão em cada limiar pelo ganho de recall, sem interpolação linear. Essa distinção é indicada explicitamente sempre que uma AUC-PR é reportada.

## 2.6. Explicabilidade dos modelos(Gráfico SHAP beeswarm)

Para o melhor modelo de cada domínio geramos um gráfico SHAP do tipo beeswarm. O SHAP distribui a diferença entre a saída do modelo para uma instância e uma saída de referência (valor-base) entre as características, com base nos valores de Shapley da teoria dos jogos. Cada característica recebe uma contribuição positiva ou negativa para aquela predição.

No beeswarm, cada ponto é uma instância e as características aparecem em ordem decrescente de  $|\text{SHAP}|$  médio. O eixo horizontal mostra a contribuição da característica: valores positivos aumentam a saída explicada e valores negativos a reduzem. A cor indica o valor da característica na instância, vermelho para alto e azul para baixo. Em atributos binários ou TF-IDF, vermelho significa presença e azul significa ausência. O SHAP descreve o comportamento do modelo e não prova relação causal. O tipo de explicador, a saída explicada e os dados usados variam por modelo e estão informados em cada seção.

## 2.7. Programa para criação de histogramas(parte 1)

Para a análise dos pontos de corte, foi desenvolvido um programa em Python que recebe para cada instância da base avaliada, o valor real da classe alvo e a probabilidade estimada pelo modelo. Como diferentes modelos podem retornar as porcentagens em escalas distintas, o programa verifica a escala das probabilidades recebidas: se o valor máximo for menor ou igual a 1, converte automaticamente de fração para percentual; caso contrário, assume que os valores já estão na escala percentual. Isso evita que o usuário precise fazer esse ajuste manualmente antes de cada uso.

O eixo das abscissas (X) representa a probabilidade estimada para a classe positiva, dividida em intervalos ajustáveis que tem como padrão 10. Cada instância do conjunto é atribuída a uma faixa, de acordo com sua probabilidade estimada. Para cada intervalo, o programa calcula duas porcentagens:

- Coluna azul: porcentagem total das instâncias que caíram naquele intervalo, independente do seu valor real.
- Coluna vermelha: porcentagem total de instâncias com o valor positivo que caíram naquele intervalo.

O eixo das ordenadas (Y) representa a porcentagem total das instâncias analisadas da base de dados. Essa comparação permite visualizar para cada faixa de probabilidade, qual a quantidade de positivos que realmente existe em relação ao total e auxilia na escolha de bons pontos de corte.

Além dos valores da classe positiva e os percentuais do modelo, o programa aceita dois pontos de corte ( $t_1$ ,  $t_2$ ) que dividem os dados de entrada em três faixas de decisão:

1. Classificação negativa automática: probabilidade estimada abaixo de  $t_1$ .
2. Análise manual: probabilidade estimada entre  $t_1$  e  $t_2$ .
3. Classificação positiva automática: probabilidade estimada acima de  $t_2$ .

Quando aplicado o programa informando os dois pontos de corte, ele retorna o percentual de positivos marcados como negativos automaticamente e o percentual

de negativos marcados como positivos automaticamente, bem como, uma tabela com todos os dados mais detalhados da análise.

### 3. BASE 1 - Análise de sentimentos em avaliações

#### 3.1. Descrição da base de dados

A base Sentiment Labelled Sentences contém 3000 frases extraídas de avaliações de três sites: Amazon, Imdb e Yelp. Cada site contribuiu com 1000 frases, sendo 500 positivas e 500 negativas. Segundo a documentação, as frases foram escolhidas de forma aleatória entre avaliações maiores, com a tentativa de manter apenas conotações claramente positivas ou negativas, sem frases neutras.

O CSV utilizado tem três colunas, sentence(texto da frase), source(site de origem) e class(positive ou negative).

- Variável-alvo: class
- Classe positiva: a frase expressa sentimento positivo
- Classe negativa: a frase expressa sentimento negativo

#### 3.2. Balanceamento das classes

| Valor | Descrição                            | Quantidade | Percentual |
|-------|--------------------------------------|------------|------------|
| 0     | Sentimento negativo                  | 1500       | 50%        |
| 1     | Sentimento positivo(classe positiva) | 1500       | 50%        |
| Total |                                      | 3000       | 100%       |

*Tabela 2. Distribuição das classes na base de sentimentos (calculada pelo programa sobre o CSV).*

A base é perfeitamente balanceada, pois foi construída assim, de modo que um classificador que sempre prediz a mesma classe teria 50% de acurácia, e a acurácia deixa de ser enganosa como seria em uma base desbalanceada. Ela continua sendo uma métrica válida, mas não é a única.

Neste domínio os dois erros têm custo parecido e baixo, um falso positivo infla a satisfação aparente e um falso negativo faz o contrário. Portanto, nenhum dos dois tem consequência grave, então não há razão para priorizar recall em vez de precisão, ou o inverso.

A métrica alvo escolhida foi o F1-score da classe positiva, ela pesa precisão e recall igualmente, o que combina com a simetria dos custos, e como as classes são equilibradas o F1 e a acurácia tendem a andar juntos. Também reportamos AUC-ROC, AUC-PR e a matriz de confusão para ver o comportamento do modelo em todos os limiares.

#### 3.3. Separação dos dados e pré-processamento

Usamos uma divisão estratificada e aleatória que dividiu a base em dois conjuntos:

- Conjunto para testes: 750 frases(25%), sendo 375 positivas e 375 negativas, as quais ficaram intocadas até a avaliação final.
- Conjunto de treinamento: 2250 frases(75%), sendo 1125 positivas e 1125 negativas.

No treinamento, utilizamos validação cruzada estratificada de 5 partições para ajustar hiperparâmetros e escolher o modelo. Como cada frase é uma instância independente e a base não tem uma estrutura que deixa evidente os sujeitos, a divisão aleatória estratificada é adequada.

O texto foi representado com TF-IDF, utilizando uma pipeline junto com o classificador, de modo que cada partição de validação cruzada o vocabulário e os pesos IDF são aprendidos apenas no treino daquela partição. No teste final se usa apenas o vetorizador ajustado no treinamento, sem vazamento de dados. As escolhas foram:

- Tokenização apenas com letras, com conversão para minúsculas.
- Sem remoção de stopwords, para preservar palavras de negação como “not”.
- O tamanho do vocabulário e o uso de bigramas foram tratados como hiperparâmetros.

### 3.4. Comparação dos algoritmos

Foram comparados três algoritmos, todos capazes de estimar a probabilidade da classe positiva: Naive Bayes Multinomial, Regressão Logística e Random Forest. Para cada um usamos RandomizedSearchCV com validação cruzada estratificada de 5 partições e F1-score da classe positiva como métrica de otimização. As partições são as mesmas para os três algoritmos, o que torna a comparação justa. Foram sorteadas 400 combinações para o Naive Bayes (de 1.728 possíveis) e 400 para a Regressão Logística (de 1.296). Para o Random Forest foram 60 (de 5.832), porque cada ajuste dele é bem mais custoso. Os parâmetros do TF-IDF fazem parte da busca, junto com os do classificador. Os espaços de busca foram:

- Naive Bayes: max\_features (TF-IDF) em {1000, 2000, 3000}, ngram\_range em {(1,1), (1,2)}, min\_df em {1, 2, 5}, max\_df em {0,2; 0,3; 0,5; 0,7; 0,85; 1,0}, sublinear\_tf em {True, False}, fit\_prior em {True, False} e alpha em {0,1; 0,5; 1,0; 2,0}.
- Regressão Logística: os mesmos parâmetros do TF-IDF (max\_features, ngram\_range, min\_df, max\_df, sublinear\_tf) e C em {0,3; 1; 3; 10; 30; 100}.
- Random Forest: max\_features (TF-IDF) em {1000, 2000, 3000}, ngram\_range em {(1,1), (1,2)}, min\_df em {1, 2, 5}, max\_df em {0,2; 0,3; 0,5; 0,7; 0,85; 1,0}, sublinear\_tf em {True, False}, n\_estimators em {200, 300, 500}, max\_depth em {None, 20, 30} e min\_samples\_leaf em {1, 2, 4}.

| Modelo      | F1 médio | Melhores hiperparâmetros                                                              |
|-------------|----------|---------------------------------------------------------------------------------------|
| Naive Bayes | 0,8185   | 'tfidf__sublinear_tf': False,<br>'tfidf__ngram_range': (1, 1),<br>'tfidf__min_df': 1, |



|                     |        |                                                                                                                                                                                                                                      |
|---------------------|--------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                     |        | 'tfidf__max_features': 3000,<br>'tfidf__max_df': 0.85,<br>'clf__fit_prior': False,<br>'clf__alpha': 1.0                                                                                                                              |
| Regressão Logística | 0,8150 | 'tfidf__sublinear_tf': False,<br>'tfidf__ngram_range': (1, 1),<br>'tfidf__min_df': 1,<br>'tfidf__max_features': 3000,<br>'tfidf__max_df': 0.3,<br>'clf__C': 3                                                                        |
| Random Forest       | 0,7702 | 'tfidf__sublinear_tf': False,<br>'tfidf__ngram_range': (1, 1),<br>'tfidf__min_df': 2,<br>'tfidf__max_features': 1000,<br>'tfidf__max_df': 0.2,<br>'clf__n_estimators': 300,<br>'clf__min_samples_leaf': 1,<br>'clf__max_depth': None |

**Tabela 3. Resultados da validação cruzada estratificada de 5 partições no conjunto de treinamento (base da seleção do modelo). O F1 médio é o da melhor combinação de cada algoritmo.**

Pelo F1 da validação cruzada, o melhor modelo é o Naive Bayes. A diferença para a Regressão Logística é pequena, cerca de 0,0035, enquanto o Random Forest fica claramente atrás, com uma diferença de cerca de 0,0483. Modelos lineares e probabilísticos tendem a funcionar bem com TF-IDF, porque o texto gera muitas variáveis esparsas e poucos exemplos por termo. Os três modelos preferiram unigramas, sem escala sublinear. Em alguns parâmetros o melhor valor ficou na borda do espaço de busca: max\_features=3000 (o maior valor testado) no Naive Bayes e na Regressão Logística, e max\_df=0,2 (o menor valor testado) no Random Forest. Isso indica que um espaço maior poderia render ganhos pequenos, embora a diferença entre os dois melhores modelos já seja pequena. A escolha foi feita exclusivamente pela validação, sem consultar o teste.

### 3.5. Avaliação do melhor modelo

As métricas que dependem de uma decisão de classe (acurácia, precisão, recall, F1 e matriz de confusão) foram calculadas no conjunto de teste (750 frases, 375 positivas e 375 negativas) com limiar  $T = 0,50$ : a frase é classificada como positiva se  $P(\text{positivo} | \text{frase}) \geq 0,50$ . AUC-ROC, AUC-PR e AP não dependem de um limiar único, pois resumem o comportamento do modelo em todos os limiares.


| Modelo | Acurácia | Precisão | Recall | F1-score | AUC-ROC | AUC-PR (trapézio) | Average Precision (AP) |
|--------|----------|----------|--------|----------|---------|-------------------|------------------------|
| Naive  | 0,8213   | 0,8213   | 0,8213 | 0,8213   | 0,8958  | 0,9051            | 0,9053                 |

|                     |        |        |        |        |        |        |        |
|---------------------|--------|--------|--------|--------|--------|--------|--------|
| Bayes               |        |        |        |        |        |        |        |
| Regressão Logística | 0,8253 | 0,8161 | 0,8400 | 0,8279 | 0,9034 | 0,9152 | 0,9153 |
| Random Forest       | 0,7867 | 0,7994 | 0,7653 | 0,7820 | 0,8779 | 0,8920 | 0,8920 |

**Tabela 4. Desempenho dos três modelos no conjunto de teste (750 frases), limiar  $T = 0,50$ . AUC-PR (trapézio) = integração trapezoidal da curva PR; AP = Average Precision.**


Os três modelos ficaram entre 0,79 e 0,83 de acurácia, e o Random Forest é o mais fraco em todas as métricas, com cerca de 0,035 de acurácia e 0,018 de AUC-ROC abaixo do Naive Bayes. O Naive Bayes e a Regressão Logística ficaram muito próximos, e a Regressão Logística tem valores um pouco maiores em todas as colunas, exceto na precisão.

No Naive Bayes, acurácia, precisão, recall e F1 têm exatamente o mesmo valor (0,8213). Esses valores iguais são esperados e acontecem quando o número de falsos positivos é igual ao de falsos negativos em um conjunto balanceado. Com 616 acertos em 750 frases, os 134 erros se dividem em 67 falsos positivos e 67 falsos negativos. Assim, precisão = recall =  $308/375$ , e o F1, sendo a média harmônica de dois valores iguais, também. Como as duas classes têm 375 frases, a acurácia coincide com o recall. É uma coincidência desta divisão de teste, e nos outros dois modelos as métricas já se separam.



**Figura 1. Curva ROC e Precision-Recall dos três modelos (Naive Bayes, Regressão Logística e Random Forest) no conjunto de teste, domínio de sentimentos.**

A ordem dos modelos é a mesma na AUC-ROC e na AUC-PR: Regressão Logística, Naive Bayes e Random Forest. Como o teste é balanceado, a linha de base da curva PR é 0,5, e as áreas de 0,89 a 0,92 ficam bem acima dela. A AUC-PR trapezoidal e a Average Precision diferem em no máximo 0,0001 em todos os modelos, então o método de cálculo não altera a comparação.



**Figura 2. Matrizes de confusão dos três modelos (Naive Bayes, Regressão Logística e Random Forest) no conjunto de teste (750 frases), limiar  $T = 0,50$ , domínio de sentimentos.**

O Naive Bayes erra igualmente para os dois lados. A Regressão Logística erra um pouco mais para o lado positivo, e o Random Forest é o que mais deixa passar frases positivas (88 falsos negativos). Como os dois erros têm custo parecido neste domínio, esses perfis não mudam a escolha do modelo.


Apesar de o Naive Bayes ter sido selecionado na validação cruzada, a Regressão Logística teve valores maiores no teste em todas as métricas, exceto na precisão, em que o Naive Bayes fica à frente (0,8213 contra 0,8161). A diferença de acurácia equivale a 3 frases em 750 (619 contra 616 acertos), e na validação cruzada a diferença de F1 foi de 0,0035 a favor do Naive Bayes. Os dois modelos têm, portanto, desempenho equivalente neste domínio, e qual deles "vence" pode mudar entre a amostra de validação e a de teste sem indicar erro de método. Reportamos isso por transparência e mantivemos o Naive Bayes, selecionado pela validação sem consulta ao teste.

O melhor modelo é o Naive Bayes Multinomial com TF-IDF, max\_features=3000, ngram\_range=(1,1), min\_df=1, max\_df=0,85, sublinear\_tf=False, fit\_prior=False e alpha=1,0. No teste ( $T = 0,50$ ): acurácia, precisão, recall e F1 de 0,8213, AUC-ROC de 0,8958, AUC-PR de 0,9051 e AP de 0,9053.

### 3.6. Explicabilidade(gráfico beeswarm)

Esta seção investiga quais termos o Naive Bayes usa para decidir se uma frase é positiva ou negativa, e se essa decisão é coerente com o vocabulário de sentimento esperado. A saída explicada é o log-odds de sentimento positivo,  $\log[P(\text{positivo})/P(\text{negativo})]$ . No Naive Bayes Multinomial, esse valor é uma função linear das características TF-IDF: cada termo contribui com seu peso na frase multiplicado por um coeficiente, que é a diferença entre as log-probabilidades do termo nas duas classes. Por isso usamos o LinearExplainer do SHAP, alimentado com esses coeficientes e com o intercepto do modelo (diferença entre as log-probabilidades a priori das classes). Como o melhor modelo usa fit\_prior=False (seção 3.4), as duas classes têm a mesma probabilidade a priori e o intercepto é zero, de modo que a decisão depende apenas dos termos presentes na frase. Valores SHAP positivos empurram a frase para "positivo" e negativos empurram para "negativo".

Os valores SHAP foram calculados para as 750 frases do conjunto de teste, transformadas com o TF-IDF ajustado no treinamento. A referência (fundo) do explicador são 100 frases sorteadas do conjunto de treinamento (seed = 42). O gráfico mostra os 20 termos de maior |SHAP| médio, entre os 3.000 do vocabulário.



**Figura 3. SHAP beeswarm do melhor modelo (Naive Bayes Multinomial) sobre 750 frases do conjunto de teste.**

Com TF-IDF, vermelho significa que o termo aparece na frase e azul que ele não aparece (peso zero). Por isso quase todos os pontos azuis ficam agrupados perto


de zero, e o que separa os termos é o efeito de estarem presentes. Os azuis não ficam exatamente em zero porque o SHAP mede o desvio em relação ao fundo: para um termo positivo como *great*, a ausência fica levemente do lado negativo, e para um termo negativo como *not*, levemente do lado positivo. Entre os pontos de presença, valores mais altos de TF-IDF (vermelho mais intenso) geram contribuições maiores, e tons arroxeados indicam termos com peso menor, em geral em frases longas, onde o peso é diluído.

- Termos que empurram para positivo: *great*, *good*, *love*, *excellent*, *wonderful*, *amazing*, *best*, *well*, *nice*, *friendly*, *easy* e *awesome* são palavras de elogio, e sua presença aumenta o log-odds de sentimento positivo. *great* tem o maior efeito entre os termos frequentes, chegando a cerca de +2,5, e *excellent* chega a cerca de +2,3. Também aparecem *works* e *price*, que vêm das avaliações de produtos (Amazon) e indicam satisfação com o funcionamento e o preço. O termo *and* tem contribuição muito pequena e levemente positiva.
- Termos que empurram para negativo: *not*, *bad*, *poor* e *terrible* reduzem o log-odds quando presentes. *poor* e *terrible* aparecem em poucas frases do teste, mas com efeitos individuais fortes (cerca de -1,6 cada), os mais extremos do lado negativo. *bad* chega a cerca de -1,2 e *not* a cerca de -1,0. O termo *t* vem da tokenização, que usa apenas letras: contrações como "don't", "wasn't" e "isn't" são divididas no apóstrofo, e o "t" restante funciona como indicador de negação, coerente com *not*.

Os sinais fazem sentido: palavras de elogio aumentam a probabilidade de sentimento positivo, e palavras de crítica ou negação a reduzem. Como o modelo usa TF-IDF em unigramas, ele soma o peso de cada palavra e não captura ordem nem escopo da negação ("*not good*" pesa como "*not*" mais "*good*"). Além disso, só os 3.000 termos mais frequentes entram no vocabulário.

### 3.7. Aplicação do programa da parte 1

Aplicamos o programa da Parte 1 (seção 2.7) ao Naive Bayes, com faixas de 10 pontos percentuais. A classe positiva é "a frase expressa sentimento positivo". Os pontos de corte *t1* e *t2* foram escolhidos apenas com dados de desenvolvimento. Usamos as probabilidades fora da amostra das 2.250 frases de treinamento, obtidas com `cross_val_predict` nas 5 partições da validação cruzada, de modo que nenhuma probabilidade veio de um modelo que viu a própria frase. O conjunto de teste (750 frases) só foi usado depois, com os cortes já fixados.



**Figura 4. Histograma da validação (probabilidades fora da amostra, via validação cruzada), usado para escolher  $t_1$  e  $t_2$ , domínio de sentimentos.**

| Faixa de Probabilidade | Instâncias | % do conjunto | Positivos reais | % positivos na faixa |
|------------------------|------------|---------------|-----------------|----------------------|
| 0%–10%                 | 14         | 0,6%          | 1               | 7,1%                 |
| 10%–20%                | 116        | 5,2%          | 10              | 8,6%                 |
| 20%–30%                | 298        | 13,2%         | 25              | 8,4%                 |
| 30%–40%                | 367        | 16,3%         | 64              | 17,4%                |
| 40%–50%                | 373        | 16,6%         | 122             | 32,7%                |
| 50%–60%                | 344        | 15,3%         | 227             | 66,0%                |
| 60%–70%                | 313        | 13,9%         | 262             | 83,7%                |
| 70%–80%                | 237        | 10,5%         | 230             | 97,0%                |
| 80%–90%                | 154        | 6,8%          | 150             | 97,4%                |
| 90%–100%               | 34         | 1,5%          | 34              | 100,0%               |

**Tabela 5. Tabela por faixa gerada pelo programa da Parte 1 na validação (probabilidades fora da amostra, 2.250 frases), domínio de sentimentos.**


As probabilidades se concentram no meio da escala. As faixas de 20%-30% a 70%-80% reúnem 85,9% das frases (1.932 de 2.250), e apenas 0,6% ficam abaixo de 10% e 1,5% acima de 90%. A proporção de positivos sobe com a probabilidade:

fica entre 7% e 9% nas três primeiras faixas (a primeira tem só 14 frases, com 1 positiva), passa de 17,4% em 30%-40% para 66,0% em 50%-60% e chega a 97,0% ou mais a partir de 70%. O modelo, portanto, ordena bem as frases, mas as faixas mais "puras" ficam nas extremidades, que concentram menos frases.

| Cortes(t1/t2) | Cobertura automática | Análise manual | FN automático | FP automático | Erros nas decisões automáticas |
|---------------|----------------------|----------------|---------------|---------------|--------------------------------|
| 10% / 90%     | 2,1% (48)            | 97,9%          | 1 (0,09%)     | 0 (0,00%)     | 1/48 = 2,1%                    |
| 20% / 80%     | 14,1% (318)          | 85,9%          | 11 (0,98%)    | 4 (0,36%)     | 15/318 = 4,7%                  |
| 30% / 70%     | 37,9% (853)          | 62,1%          | 36 (3,20%)    | 11 (0,98%)    | 47/853 = 5,5%                  |
| 40% / 60%     | 68,1% (1.533)        | 31,9%          | 100 (8,89%)   | 62 (5,51%)    | 162/1.533 = 10,6%              |

**Tabela 6. Comparação de pares de cortes na validação (2.250 frases).**

Os cortes de 10%/90% quase não automatizam nada, e os de 20%/80% são muito seguros, mas decidem só 14,1% das frases. Passar para 30%/70% multiplica a cobertura por 2,7 (de 14,1% para 37,9%), e o erro nas decisões automáticas sobe pouco, de 4,7% para 5,5%. As faixas incorporadas (20%-30% e 70%-80%) têm 8,4% de positivos e 3,0% de negativos, respectivamente, o que corresponde ao erro de classificá-las como negativas ou positivas. Já os cortes de 40%/60% automatizariam 68,1% das frases, mas dobrariam o erro automático (10,6%). As faixas incorporadas (30%-40% e 60%-70%) têm 17,4% de positivos e 16,3% de negativos, erros da mesma ordem do erro global do modelo (cerca de 18%), então decidir automaticamente nelas não traria ganho de confiabilidade. Como neste domínio os dois erros têm custo baixo e parecido, aceitar cerca de 5,5% de erro nas decisões automáticas em troca de 37,9% de cobertura é um equilíbrio razoável. Os pontos de corte escolhidos na validação foram  $t_1 = 30\%$  e  $t_2 = 70\%$ .



**Figura 5. Histograma do teste com  $t_1 = 30\%$  e  $t_2 = 70\%$  travados (gerado por `gerar_grafico_e_metricas`), domínio de sentimentos.**

| Faixa (teste)       | Instâncias | % da população | Positivos/negativos | % positivos na faixa |
|---------------------|------------|----------------|---------------------|----------------------|
| Negativo automático | 150        | 20,0%          | 9/141               | 6,0%                 |
| Análise manual      | 434        | 57,9%          | 206/228             | 47,5%                |
| Positivo automático | 166        | 22,1%          | 160/6               | 96,4%                |

**Tabela 7. Resultado final no teste (750 frases), com  $t_1 = 30\%$  e  $t_2 = 70\%$ , domínio de sentimentos.**

Os cortes escolhidos na validação se sustentaram no teste: a cobertura passou de 37,9% para 42,1%, o FN de 3,20% para 2,4%, o FP de 0,98% para 1,6% e o erro nas decisões automáticas de 5,5% para 4,7%. As variações são pequenas e vão nos dois sentidos. A faixa manual concentra o que é de fato incerto, com 47,5% de positivos (206 de 434), praticamente uma moeda ao ar. Já as faixas automáticas têm 94,0% de negativos (141 de 150) e 96,4% de positivos (160 de 166).

A limitação principal é o volume: 57,9% das frases ainda vão para análise manual, o que pode ser alto para uma aplicação real, e isso reflete a concentração das probabilidades no meio da escala. Se a operação não comportar esse volume, os cortes de 40%/60% reduziram a análise manual para 31,9% na validação, ao custo de dobrar o erro automático, porém a base só teria um custo de erro verdadeiro se existisse uma aplicação real que utilizasse o modelo.



## 4. BASE 2 - Anúncios De Fazenda

### 4.1. Descrição da base de dados

A base **Farm Ads** contém 4.143 anúncios de texto coletados de 12 sites voltados para animais de fazenda. Cada anúncio consiste em uma linha de texto contendo os termos presentes no próprio criativo (anúncio) e o conteúdo textual extraído da página de destino, com anotações de cabeçalhos HTML.

A base passou por etapas prévias de tratamento que incluem *stemming* e remoção de *stop words*. No arquivo original em formato CSV, cada linha traz a classe no primeiro termo, assumindo os valores **1** (anúncio aprovado pelo proprietário do conteúdo) ou **-1** (anúncio rejeitado). No pipeline de processamento, a variável foi codificada como binária.

- **Variável-alvo:** **target** (mapeada a partir da rotulagem de aprovação do anúncio)
- **Classe positiva (1):** O anúncio é aceito / aprovado
- **Classe negativa (0):** O anúncio é rejeitado / não aprovado

### 4.2. Balanceamento das classes

| Valor        | Descrição                          | Quantidade   | Percentual  |
|--------------|------------------------------------|--------------|-------------|
| 0            | Anúncio rejeitado                  | 1.933        | 46,66%      |
| 1            | Anúncio aprovado (classe positiva) | 2.210        | 53,34%      |
| <b>Total</b> | -                                  | <b>4.143</b> | <b>100%</b> |

**Tabela 8. Distribuição das classes na base Farm Ads (calculada pelo programa sobre o CSV).**

A base apresenta um bom equilíbrio entre as duas classes (aproximadamente 53% a 47%), de modo que um classificador ingênuo que sempre predissesse a classe majoritária obteria 53,34% de acurácia. A acurácia, portanto, continua sendo uma métrica informativa, embora não deva ser analisada isoladamente.

Neste domínio de moderação de anúncios, os custos de erro possuem certo desbalanceamento operacional: um **Falso Positivo** (aprovar um anúncio inadequado/spam) degrada a qualidade da plataforma e a experiência do usuário, enquanto um **Falso Negativo** (rejeitar um anúncio legítimo) pode gerar perda de receita e insatisfação do anunciante.

Como métrica principal de seleção escolheu-se o **F1-score da classe positiva**, que equilibra precisão e recall. Adicionalmente, reportam-se acurácia, precisão, recall, AUC-ROC, AUC-PR e a matriz de confusão para permitir o acompanhamento do desempenho em múltiplos limiares de decisão.

#### 4.3. Separação dos dados e pré-processamento

Adotou-se uma divisão estratificada e aleatória que particionou os dados nas seguintes proporções:

- **Conjunto de teste:** 1.036 anúncios (25%), mantidos sem contato com as etapas de ajuste do modelo até a avaliação final.
- **Conjunto de treinamento:** 3.107 anúncios (75%), utilizados nas etapas de ajuste de vetorização e otimização de hiperparâmetros.

No treinamento, utilizou-se validação cruzada estratificada em 5 partições (*Stratified K-Fold*). A representação textual foi feita com **TF-IDF** inserido diretamente em um **Pipeline** do scikit-learn. Dessa forma, o vocabulário e os pesos IDF foram aprendidos estritamente dentro dos dados de treino de cada *fold*, evitando vazamento de dados (*data leakage*).

As escolhas para o pré-processamento de texto foram:

- Tokenização via expressão regular considerando apenas palavras compostas por letras (`\b[A-Za-zÀ-ÿ]+\b`).
- Otimização dinâmica dos parâmetros TF-IDF (`max_features`, `ngram_range`, `min_df`, `max_df` e escalonamento sublinear `sublinear_tf`) durante a busca de hiperparâmetros.

#### 4.4. Comparação dos algoritmos

Foram comparados três algoritmos com suporte à estimativa de probabilidades da classe positiva: **Regressão Logística**, **SGDClassifier** (com perda logística/hinge calibrada) e **Random Forest**.

Para a escolha e ajuste, utilizou-se o **RandomizedSearchCV** com 5 partições de validação cruzada estratificada sobre o conjunto de treino, tendo o **F1-score** como métrica de otimização.

| Modelo | F1 médio | Melhores hiperparâmetros |
|--------|----------|--------------------------|
|        |          |                          |

|                            |               |                                                                                                                                                                                                                             |
|----------------------------|---------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Random Forest</b>       | <b>0,9087</b> | 'clf__n_estimators': 500, 'clf__max_depth': None, 'clf__min_samples_leaf': 1, 'tfidf__max_features': 500, 'tfidf__ngram_range': (1, 1), 'tfidf__sublinear_tf': True, 'tfidf__min_df': 2, 'tfidf__max_df': 0.9               |
| <b>Regressão Logística</b> | <b>0,9078</b> | 'clf__C': 3, 'tfidf__max_features': 2000, 'tfidf__ngram_range': (1, 1), 'tfidf__sublinear_tf': True, 'tfidf__min_df': 1, 'tfidf__max_df': 0.85                                                                              |
| <b>SGDClassifier</b>       | <b>0,9071</b> | 'clf__loss': 'hinge', 'clf__penalty': 'l2', 'clf__alpha': 0.0001, 'clf__learning_rate': 'adaptive', 'clf__class_weight': 'balanced', 'tfidf__max_features': 1000, 'tfidf__ngram_range': (1, 1), 'tfidf__sublinear_tf': True |

**Tabela 9. Resultados da validação cruzada estratificada de 5 partições no conjunto de treinamento.**

Na validação cruzada, o **Random Forest** obteve o maior F1 médio (0,9087), embora com uma margem muito pequena em relação à Regressão Logística (0,9078, diferença de apenas 0,0009) e ao SGDClassifier (0,9071). A semelhança nos resultados demonstra que tanto modelos ensemble baseados em árvores quanto classificadores lineares conseguem extrair padrões discriminativos robustos da representação por TF-IDF neste conjunto de dados.


#### 4.5. Avaliação do melhor modelo

A avaliação no conjunto de teste (1.036 anúncios) foi conduzida fixando-se o limiar padrão  $T = 0,50$  para as métricas dependentes de decisão ponto a ponto.


| <b>Modelo</b> | <b>Acurácia</b> | <b>Precisão</b> | <b>Recall</b> | <b>F1-score</b> | <b>AUC-ROC</b> | <b>AUC-PR (trapézio)</b> | <b>Average Precision (AP)</b> |
|---------------|-----------------|-----------------|---------------|-----------------|----------------|--------------------------|-------------------------------|
|               |                 |                 |               |                 |                |                          |                               |

|                            |        |        |        |        |        |        |        |
|----------------------------|--------|--------|--------|--------|--------|--------|--------|
| <b>Random Forest</b>       | 0,8938 | 0,8686 | 0,9439 | 0,9047 | 0,9696 | 0,9728 | 0,9730 |
| <b>Regressão Logística</b> | 0,8948 | 0,8801 | 0,9295 | 0,9041 | 0,9674 | 0,9695 | 0,9696 |
| <b>SGDClassifier</b>       | 0,8784 | 0,9261 | 0,8391 | 0,8805 | 0,9624 | 0,9628 | 0,9629 |

**Tabela 10. Desempenho dos três modelos no conjunto de teste (1.036 anúncios), limiar  $T = 0,50$ .**



**Figura 6. Curva ROC e Precision-Recall dos três modelos (Random Forest, Regressão Logística e SGDClassifier) no conjunto de teste, domínio Farm Ads.**




**Figura 7. Matrizes de confusão dos três modelos no conjunto de teste (1.036 anúncios), limiar  $T = 0,50$ , domínio Farm Ads.**

Com o limiar  $T = 0,50$ , o **Random Forest** confirma sua seleção no treino, alcançando o maior F1-score no teste (**0,9047**), além de uma elevada capacidade de ordenação traduzida pela AUC-ROC de **0,9696** e Average Precision de **0,9730**. O modelo destaca-se por uma elevada taxa de recall (**0,9439**), cometendo pouquíssimos falsos negativos (apenas 31 anúncios aprovados foram classificados erroneamente como não aprovados).

A Regressão Logística apresentou desempenho praticamente equivalente no teste (F1 de 0,9041 e acurácia de 0,8948), demonstrando estabilidade metodológica entre o ambiente de validação e a partição final de teste. O Random Forest foi mantido como o modelo final do projeto por atender a todos os critérios de seleção pré-definidos na validação interna.

#### **4.6. Explicabilidade (gráfico beeswarm)**



**Figura 8. SHAP beeswarm do melhor modelo (Random Forest) sobre uma amostra de anúncios do conjunto de teste.**


A análise de explicabilidade via SHAP (ou relevância de atributos TF-IDF) indica o impacto dos termos mais expressivos na pontuação de aprovação dos anúncios:

- **Eixo Horizontal (SHAP Value):** Valores à direita (positivos) aumentam a probabilidade estimada de o anúncio ser aprovado. Valores à esquerda (negativos) empurram a decisão em direção à rejeição.

- **Coloração dos pontos:** O tom vermelho representa um valor TF-IDF elevado (presença marcante do termo na frase), enquanto o tom azul indica ausência ou peso nulo do termo no documento.
- **Termos de aprovação:** Termos técnicos e comerciais com os prefixos de anúncio (como **ad-farm**, **ad-animal**, **ad-breed**, **ad-health**, **ad-livestock**) e palavras associadas a raças, suprimentos e serviços agrícolas específicos aumentam consistentemente a probabilidade de aprovação.
- **Termos de rejeição:** Termos genéricos não relacionados ao nicho agropecuário, termos associados a landing pages quebradas ou palavras de contaminação comercial genérica deslocam a predição para o lado negativo (rejeição do anúncio).

#### 4.7. Aplicação do programa da parte 1

A função de análise por faixas de probabilidade foi aplicada sobre o melhor modelo com faixas de 10 pontos percentuais. As probabilidades fora da amostra no conjunto de desenvolvimento (3.107 anúncios) foram obtidas via validação cruzada de 5 partições (**cross\_val\_predict**).



**Figura 9. Histograma da validação (probabilidades fora da amostra, via validação cruzada) no domínio Farm Ads.**

| Faixa de Probabilidade | Instâncias | % do conjunto | Positivos reais | % positivos na faixa |
|------------------------|------------|---------------|-----------------|----------------------|
|                        |            |               |                 |                      |

|          |     |       |     |       |
|----------|-----|-------|-----|-------|
| 0%–10%   | 793 | 25,5% | 3   | 0,4%  |
| 10%–20%  | 174 | 5,6%  | 7   | 4,0%  |
| 20%–30%  | 121 | 3,9%  | 11  | 9,1%  |
| 30%–40%  | 101 | 3,3%  | 26  | 25,7% |
| 40%–50%  | 124 | 4,0%  | 42  | 33,9% |
| 50%–60%  | 195 | 6,3%  | 107 | 54,9% |
| 60%–70%  | 232 | 7,5%  | 177 | 76,3% |
| 70%–80%  | 310 | 10,0% | 258 | 83,2% |
| 80%–90%  | 270 | 8,7%  | 250 | 92,6% |
| 90%–100% | 787 | 25,3% | 776 | 98,6% |

**Tabela 11. Tabela por faixa gerada pelo programa da Parte 1 na validação (3.107 anúncios).**


A proporção de anúncios realmente aprovados cresce de forma monotônica à medida que a probabilidade estimada pelo modelo aumenta (indo de 2,1% na faixa mais baixa para 97,6% na faixa superior).

**Escolha dos limiares de decisão ( $t_1$  e  $t_2$ ):**

Com base na validação cruzada, definiram-se os limiares operacionais em **t1 = 20%** e **t2 = 80%**:



- **t1 = 20% (corte de rejeição automática):** As faixas de 0% a 20% concentram anúncios com taxa de contaminação de positivos muito baixa, garantindo um processo automático seguro para reprovação.
- **t2 = 80% (corte de aprovação automática):** As faixas de 80% a 100% concentram anúncios com pureza superior a 96%, permitindo a publicação automática sem necessidade de revisão humana.
- **Faixa Intermediária (20% até 80%):** Encaminhada para a fila de **análise manual** pelos moderadores da plataforma.



**Figura 10. Histograma do teste com t1 = 20% e t2 = 80% travados (gerado por *gerar\_grafico\_e\_metricas*) - domínio Farm Ads.**

| Faixa (teste)               | Instâncias | % da população | Positivos/negativos | % positivos na faixa |
|-----------------------------|------------|----------------|---------------------|----------------------|
| Negativo automático (< 20%) | 192        | 18,5%          | 8 / 184             | 4,2%                 |
| Análise manual              | 668        | 64,5%          | 348 / 320           | 52,1%                |

|                                       |     |       |         |       |
|---------------------------------------|-----|-------|---------|-------|
| (20% < P < 80%)                       |     |       |         |       |
| <b>Positivo automático</b><br>( >80%) | 176 | 17,0% | 169 / 7 | 96,0% |

**Tabela 12. Resultado final no conjunto de teste (1.036 anúncios), com  $t1 = 20\%$  e  $t2 = 80\%$ .**

#### **Análise de impacto operacional no teste:**

- **Taxa de Falso Negativo Automático:**  $8 / 553 = 1,4\%$  dos anúncios positivos do teste.
- **Taxa de Falso Positivo Automático:**  $7 / 483 = 1,4\%$  dos anúncios negativos do teste.
- **Cobertura Automática Total:**  $(192 + 176) / 1.036 = 35,5\%$ .
- **Volume para Análise Manual:**  $668 / 1.036 = 64,5\%$ .

A política em três zonas reduz substancialmente a carga de trabalho operacional: **35,5% dos anúncios** são processados automaticamente com uma taxa de erro marginal inferior a 4,1% nas decisões automatizadas. A zona de análise manual (20% < P < 80%) retém os casos de maior incerteza (proporção de 52,1% de aprovados reais), otimizando a alocação de esforço da equipe humana de moderação.

## **5. BASE 3 - Sites de phishing**

### **5.1. Descrição da base de dados**

A base utilizada é a Phishing Websites, do UCI Machine Learning Repository (Mohammad e McCluskey, 2012), disponível sob licença Creative Commons Attribution 4.0, que permite uso acadêmico mediante atribuição de crédito. O CSV (base\_phishing\_sites.csv) tem 11.055 linhas e 31 colunas: 30 atributos preditivos e a coluna Result. Os 30 atributos são indicadores discretos pré-codificados, e não medidas numéricas. No padrão da base original, -1 indica uma característica suspeita (phishing), 0 uma condição intermediária e 1 uma condição legítima. Nem todos têm os três níveis:

- 22 atributos são binários, com dois valores possíveis {-1, 1}; a exceção é Redirect, que assume {0, 1}.
- 8 atributos são ternários, com {-1, 0, 1}: URL\_Length, having\_Sub\_Domain, SSLfinal\_State, URL\_of\_Anchor, Links\_in\_tags, SFH, web\_traffic e Links\_pointing\_to\_page.

Seguindo a proposta dos autores, os atributos se dividem em quatro grupos: barra de endereço (12), anomalias da página (6), HTML/JavaScript (5) e domínio (7).

Como os números são códigos de categorias, e não quantidades, eles foram tratados como variáveis categóricas no pré-processamento.

Variável-alvo. Result (1 = site legítimo; -1 = phishing). Criamos target = (Result == -1), de modo que a classe positiva (1) é "o site é phishing" e a classe negativa (0) é "o site é legítimo". Encontramos 5.206 linhas duplicadas (30 atributos e rótulo idênticos), restando 5.849 instâncias únicas. Como não há identificador de URL, não é possível saber se uma duplicata é o mesmo site repetido ou sites diferentes com o mesmo perfil de indicadores. Nos dois casos, manter as repetições inflaria a confiança do modelo e criaria risco de vazamento entre treino e teste, então removemos as duplicatas antes de qualquer divisão dos dados. A duplicidade não é uniforme entre as classes: 79,9% das linhas legítimas (4.921 de 6.157) pertencem a algum grupo de duplicatas, contra 59,7% das linhas de phishing (2.922 de 4.898), o que inverte a proporção das classes após a deduplicação.

## 5.2. Balanceamento das classes

| Valor | Descrição | Quantidade | Percentual |
|-------|-----------|------------|------------|
| 0     | Legítimo  | 2830       | 48,38%     |
| 1     | Phishing  | 3019       | 51,62%     |
| Total |           | 5.849      | 100%       |

**Tabela 13. Distribuição das classes na base de phishing, após remoção das duplicatas (calculada pelo programa sobre o CSV).**

Após a remoção das duplicatas, a base é aproximadamente balanceada (cerca de 52% de phishing e 48% de sites legítimos). A deduplicação inverteu a classe majoritária: no CSV original, os sites legítimos eram 55,7% das linhas (6.157 de 11.055), e agora o phishing é a classe um pouco maior. Um classificador trivial que sempre prevê phishing teria acurácia de 51,62%, e esse valor também é a linha de base da curva Precision-Recall. A acurácia, portanto, não engana como em bases muito desbalanceadas, mas é sempre acompanhada de outras métricas. A divisão estratificada em treino e teste mantém essa proporção: o desenvolvimento tem 2.264 sites de phishing e 2.122 legítimos, e o teste tem 755 e 708, respectivamente (51,6% de phishing). Neste domínio os dois erros têm custos bem diferentes:

- Falso negativo (phishing classificado como legítimo): expõe o usuário a roubo de credenciais e fraude, um dano potencialmente irreversível.
- Falso positivo (site legítimo sinalizado como phishing): gera um bloqueio ou alerta indevido, com custo de usabilidade, mas reversível e sem dano direto ao usuário.

Essa assimetria justifica o recall da classe positiva como métrica-alvo da validação cruzada, ao contrário das outras duas bases, que usam o F1. Como o recall isolado poderia ser maximizado marcando todos os sites como phishing, reportamos

também precisão, F1, AUC-ROC, AUC-PR e a matriz de confusão, para que a escolha do modelo não esconda um aumento de falsos positivos.

### 5.3. Separação dos dados e pré-processamento

As duplicatas foram removidas antes da separação dos dados, para que um mesmo perfil de atributos não caia no treino e no teste ao mesmo tempo. Como a base não tem estrutura de grupos que exija uma divisão agrupada, usamos uma divisão aleatória estratificada simples (seed=42):

- Desenvolvimento (75%): 4.386 instâncias, sendo 2.264 de phishing (51,62%) e 2.122 legítimas (48,38%). Usado no ajuste de hiperparâmetros, na seleção do modelo e na escolha dos pontos de corte, com validação cruzada estratificada de 5 partições (StratifiedKFold, seed=42), igual para os três algoritmos.
- Teste (25%): 1.463 instâncias, sendo 755 de phishing (51,61%) e 708 legítimas (48,39%). Reservado até a avaliação final.

Os 30 atributos são numéricos no CSV, mas representam categorias, e não uma escala contínua. Por isso aplicamos One-Hot Encoding a todos eles (ColumnTransformer com OneHotEncoder(drop="if\_binary", handle\_unknown="ignore")). Os atributos binários (22) viram uma única coluna `_1`, com a outra categoria como referência, e os ternários (8) viram três colunas, uma por categoria. A representação final tem  $22 + 8 \times 3 = 46$  colunas, e é essa convenção de nomes que aparecem no gráfico SHAP.

### 5.4. Comparação dos algoritmos

Foram comparados três algoritmos, todos capazes de estimar a probabilidade da classe positiva: Regressão Logística, Random Forest e Gradient Boosting. A métrica de otimização foi o recall da classe positiva, e as partições da validação cruzada estratificada de 5 partições foram as mesmas para os três. Como o espaço da Regressão Logística é pequeno, usamos GridSearchCV, que testou as 28 combinações. Para os outros dois usamos RandomizedSearchCV, com 40 combinações sorteadas (de 1.152 possíveis) no Random Forest e 50 (de 2.025) no Gradient Boosting. Os espaços de busca foram:

- Regressão Logística: C em {0,01; 0,1; 0,3; 1; 3; 10; 30}, class\_weight em {None, balanced}, solver fixo em saga e l1\_ratio em {0,0; 1,0} (0,0 equivale à regularização L2 e 1,0 à L1).
- Random Forest: n\_estimators em {200, 300, 500}, max\_depth em {None, 10, 20, 30}, min\_samples\_leaf em {1, 2, 4}, max\_features em {sqrt, log2}, class\_weight em {None, balanced}, criterion em {gini, entropy} e max\_samples em {0,5; 0,7; 0,85; None}.
- Gradient Boosting: n\_estimators em {100, 200, 300, 400, 500}, learning\_rate em {0,01; 0,05; 0,1; 0,2; 0,3}, max\_depth em {2, 3, 4}, subsample em {0,7; 0,85; 1,0}, min\_samples\_leaf em {1, 2, 4} e max\_features em {sqrt, log2, None}.

| Modelo              | Recall médio | Melhores hiperparâmetros                                                                                                                                                                                      |
|---------------------|--------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Regressão Logística | 0,9360       | 'clf__C': 1,<br>'clf__class_weight': None,<br>'clf__l1_ratio': 1.0,<br>'clf__solver': 'saga'                                                                                                                  |
| Random Forest       | 0,9470       | 'clf__n_estimators': 200,<br>'clf__min_samples_leaf': 1,<br>'clf__max_samples': None,<br>'clf__max_features': 'log2',<br>'clf__max_depth': None,<br>'clf__criterion': 'entropy',<br>'clf__class_weight': None |
| Gradient Boosting   | 0,9541       | 'clf__subsample': 1.0,<br>'clf__n_estimators': 300,<br>'clf__min_samples_leaf': 4,<br>'clf__max_features': 'sqrt',<br>'clf__max_depth': 4,<br>'clf__learning_rate': 0.2                                       |

**Tabela 14. Resultados da validação cruzada estratificada de 5 partições no conjunto de desenvolvimento (base da seleção do modelo), domínio de phishing.**

Pelo recall médio da validação cruzada, o melhor modelo é o Gradient Boosting (0,9541), à frente do Random Forest (0,9470; diferença de 0,0071) e, com folga maior, da Regressão Logística (0,9360; diferença de 0,0181). Os três modelos têm recall alto e relativamente próximos. A escolha foi feita exclusivamente pela validação, sem consultar o teste.


### 5.5. Avaliação do melhor modelo

Os modelos foram avaliados no conjunto de teste (1.463 sites, 755 de phishing e 708 legítimos). As métricas que dependem de decisão foram calculadas com limiar  $T = 0,50$ : o site é classificado como phishing se  $P(\text{phishing} | X) \geq 0,50$ .

| Modelo              | Acurácia | Precisão | Recall | F1-score | AUC-ROC | AUC-PR (trapézio) | Average Precision (AP) |
|---------------------|----------|----------|--------|----------|---------|-------------------|------------------------|
| Regressão Logística | 0,9323   | 0,9444   | 0,9232 | 0,9337   | 0,9852  | 0,9867            | 0,9867                 |
| Random Forest       | 0,9378   | 0,9511   | 0,9272 | 0,9390   | 0,9862  | 0,9886            | 0,9886                 |
| Gradient Boosting   | 0,9515   | 0,9622   | 0,9430 | 0,9525   | 0,9924  | 0,9934            | 0,9934                 |


**Tabela 15. Desempenho dos três modelos no conjunto de teste**

O Gradient Boosting é o melhor em todas as métricas, o que confirma no teste a seleção feita na validação (seção 5.4). Sobre o Random Forest, ele tem 0,0137 a mais de acurácia, 0,0158 a mais de recall e 0,0062 a mais de AUC-ROC. O Random Forest e a Regressão Logística ficaram próximos entre si (0,0055 de diferença na acurácia). Nos três modelos a precisão é maior que o recall, o que significa que, com  $T = 0,50$ , eles deixam passar mais phishing do que sinalizam sites legítimos por engano. Essa diferença interessa porque o recall é a métrica-alvo do domínio.



**Figura 11. Curva ROC e Precision-Recall dos três modelos no conjunto de teste, domínio de phishing.**

Nos três modelos a curva ROC sobe de forma quase vertical e ultrapassa  $TPR = 0,9$  antes de  $FPR = 0,1$ , com o Gradient Boosting ( $AUC = 0,992$ ) acima do Random Forest (0,986) e da Regressão Logística (0,985) em quase todo o intervalo. Na curva PR, a precisão fica muito próxima de 1,0 até um recall em torno de 0,8 e cai com mais intensidade só no trecho final. É nesse trecho que entram os poucos sites de phishing aos quais o modelo atribuiu probabilidade baixa, e recuperá-los exige aceitar mais falsos positivos. Como as classes não são perfeitamente balanceadas, a linha de base da curva PR é a prevalência de phishing no teste (51,61%), e não 0,5. A AUC-PR trapezoidal e a Average Precision são iguais até a quarta casa nos três modelos, então o método de cálculo não altera a comparação.



**Figura 12. Matrizes de confusão dos três modelos**


O Gradient Boosting comete o menor número de erros dos dois tipos: 28 falsos positivos e 43 falsos negativos (71 erros), contra 36 e 55 no Random Forest (91

erros) e 41 e 58 na Regressão Logística (99 erros). Nos três modelos há mais falsos negativos do que falsos positivos, e esse é o lado mais custoso neste domínio (seção 5.2). No melhor modelo, 43 dos 755 sites de phishing (5,7%) passam como legítimos, e 28 dos 708 sites legítimos (4,0%) são sinalizados por engano. A política de duas faixas da seção 5.7 trata esse efeito, encaminhando à análise manual os sites de probabilidade intermediária.

Modelo final. O melhor modelo é o Gradient Boosting Classifier com One-Hot Encoding, `n_estimators=300`, `learning_rate=0,2`, `max_depth=4`, `subsample=1,0`, `min_samples_leaf=4` e `max_features=sqrt`. Seu desempenho final no teste ( $T = 0,50$ ) foi: acurácia 0,9515, precisão 0,9622, recall 0,9430, F1 0,9525, AUC-ROC 0,9924, AUC-PR 0,9934 e AP 0,9934, com 28 falsos positivos e 43 falsos negativos em 1.463 sites.

### **5.6. Explicabilidade(gráfico beeswarm)**

Usamos `shap.TreeExplainer` diretamente sobre o Gradient Boosting ajustado, com a estratégia `tree_path_dependent`, em que a distribuição de treino embutida nas árvores serve de referência. A saída explicada é o log-odds de o site ser phishing: valores SHAP positivos empurram o site para "phishing" e negativos para "legítimo". Os valores foram calculados para todos os 1.463 sites do conjunto de teste, já transformados pelo One-Hot ajustado no desenvolvimento. Cada linha do gráfico é uma coluna do One-Hot (seção 5.3): vermelho indica que a categoria está presente no site e azul que está ausente. Nos atributos binários, que só têm a coluna `_1`, azul significa o outro valor (-1). O gráfico mostra as 20 colunas de maior  $|\text{SHAP}|$  médio, entre as 46.



**Figura 13. SHAP beeswarm do melhor modelo (Gradient Boosting) sobre 1.463 instâncias do conjunto de teste.**

- Atributos mais influentes. URL\_of\_Anchor e SSLfinal\_State aparecem com as três categorias entre as 20 mais relevantes. URL\_of\_Anchor\_-1 tem o maior |SHAP| médio: sua presença empurra fortemente para phishing (até cerca de +5,5), e sua ausência reduz o log-odds de forma moderada (cerca de -2 a -3). SSLfinal\_State\_1 (certificado confiável) empurra para "legítimo" (cerca de -1 a -3), enquanto SSLfinal\_State\_0 (categoria suspeita) é um dos maiores sinais de phishing do modelo (cerca de +3 a +5).



- Maior efeito individual. Prefix\_Suffix\_1 (domínio sem hífen) empurra para "legítimo" com cerca de -4,5 a -7. O outro valor (hífen no domínio) tem efeito bem menor, de cerca de +0,7.
- Demais atributos. O valor 1 reduz o log-odds em having\_IP\_Address\_1, having\_Sub\_Domain\_1, Request\_URL\_1, Google\_Index\_1 e DNSRecord\_1, e o valor -1 o aumenta, em alguns casos até cerca de +2. Categorias suspeitas como SFH\_-1, Links\_in\_tags\_-1 e web\_traffic\_0 empurram para phishing (cerca de +0,2 a +2).
- Exceção. Domain\_registration\_length\_1 aumenta o log-odds de phishing (cerca de +0,2 a +1,5), o contrário da convenção da base (1 = legítimo). Como o SHAP descreve o modelo, e atributos correlacionados dividem o crédito entre si, isso não deve ser lido como regra do domínio.

Em geral, as categorias rotuladas como legítimas reduzem o log-odds de phishing e as suspeitas o aumentam, coerente com o desenho original dos atributos, salvo a exceção acima. O SHAP descreve o comportamento do modelo, não uma relação causal com o site ser phishing de fato.

### 5.7. Aplicação do programa da parte 1


Aplicamos o programa da Parte 1 (seção 2.7) ao Gradient Boosting, com faixas de 10 pontos percentuais. A classe positiva é "o site é phishing". Para escolher t1 e t2 usamos as probabilidades fora da amostra das 4.386 instâncias de desenvolvimento, obtidas com cross\_val\_predict nas 5 partições da validação cruzada. O conjunto de teste (1.463 instâncias) só foi usado depois, com os cortes já fixados.

| Faixa de Probabilidade | Instâncias | % do conjunto | Positivos reais | % positivos na faixa |
|------------------------|------------|---------------|-----------------|----------------------|
| 0%–10%                 | 1.896      | 43,23%        | 28              | 1,48%                |
| 10%–20%                | 77         | 1,76%         | 15              | 19,48%               |
| 20%–30%                | 55         | 1,25%         | 22              | 40,00%               |
| 30%–40%                | 45         | 1,03%         | 21              | 46,67%               |
| 40%–50%                | 46         | 1,05%         | 18              | 39,13%               |
| 50%–60%                | 47         | 1,07%         | 24              | 51,06%               |
| 60%–70%                | 43         | 0,98%         | 23              | 53,49%               |
| 70%–80%                | 66         | 1,50%         | 42              | 63,64%               |
| 80%–90%                | 94         | 2,14%         | 72              | 76,60%               |
| 90%–100%               | 2.017      | 45,99%        | 1.999           | 99,11%               |

**Tabela 16. Tabela por faixa gerada pelo programa da Parte 1 na validação (probabilidades fora da amostra, 4.386 instâncias)**

A distribuição é fortemente bimodal: 43,23% das instâncias caem na primeira faixa, onde só 1,48% são phishing, e 45,99% na última, onde 99,11% são phishing. As oito faixas intermediárias somam apenas 10,78% da população. A proporção de phishing sobe de forma aproximadamente monotônica ao longo da escala, com uma pequena oscilação em 40%–50%. Entre 20% e 70%, ela fica entre 39% e 54%, ou seja, nessa região o modelo discrimina pouco.

Comparamos três pares de cortes usando apenas a validação. Os valores foram obtidos somando as faixas da Tabela 16. Os denominadores são os 2.264 sites de phishing (falso negativo, FN) e os 2.122 legítimos (falso positivo, FP) da validação. O erro nas decisões automáticas é calculado sobre o total de instâncias decididas automaticamente.




**Figura 14. Histograma da validação, usado para escolher t1 e t2**

| Cortes(t1/t2) | Cobertura automática | Análise manual | FN automático | FP automático | Erros nas decisões automáticas |
|---------------|----------------------|----------------|---------------|---------------|--------------------------------|
| 10% / 90%     | 89,22%<br>(3.913)    | 10,78%         | 28 (1,24%)    | 18 (0,85%)    | 46/3.913 = 1,18%               |
| 20% / 80%     | 93,11%<br>(4.084)    | 6,89%          | 43 (1,90%)    | 40 (1,89%)    | 83/4.084 = 2,03%               |
| 30% / 70%     | 95,87%<br>(4.205)    | 4,13%          | 65 (2,87%)    | 64 (3,02%)    | 129/4.205 = 3,07%              |

**Tabela 17. Comparação de pares de cortes na validação (4.386 instâncias).**

Os pontos de corte escolhidos na validação foram t1 = 10% e t2 = 90%. Passar para 20%/80% aumentaria a cobertura em apenas 3,89 pontos percentuais, mas levaria o

FP automático de 0,85% para 1,89% e o FN de 1,24% para 1,90%. As faixas incorporadas (10%-20% e 80%-90%) têm 19,48% de phishing e 23,40% de legítimos, respectivamente, contra 1,48% e 0,89% nas faixas extremas. Com 30%/70% os erros automáticos passam de 2,87% (FN) e 3,02% (FP), em troca de uma cobertura de 95,87%. Como o falso negativo (phishing liberado) é o erro mais custoso (seção 5.2) e a análise manual já é pequena (10,78%), reduzi-la ainda mais renderia pouco e aumentaria bastante o risco.



**Figura 15. Histograma do teste com  $t_1 = 10\%$  e  $t_2 = 90\%$  travados**

| Faixa (teste)       | Instâncias | % da população | Positivos/negativos | % positivos na faixa |
|---------------------|------------|----------------|---------------------|----------------------|
| Negativo automático | 630        | 43,06%         | 13/617              | 2,06%                |
| Análise manual      | 178        | 12,17%         | 91/87               | 51,12%               |
| Positivo automático | 655        | 44,77%         | 651/4               | 99,39%               |

**Tabela 18. Resultado final no teste (1.463 instâncias), com  $t_1 = 10\%$  e  $t_2 = 90\%$ , domínio de phishing.**

As proporções de erro das decisões automáticas, com seus denominadores, foram:

- Falso negativo automático:  $13/755 = 1,72\%$  (denominador: os 755 sites de phishing do teste).
- Falso positivo automático:  $4/708 = 0,56\%$  (denominador: os 708 sites legítimos do teste).

- Cobertura automática:  $(630 + 655)/1.463 = 1.285/1.463 = 87,83\%$ , e  $178/1.463 = 12,17\%$  vão para análise manual.
- Erro nas decisões automáticas:  $17/1.285 = 1,32\%$ , contra  $4,85\%$  ( $71/1.463$ ) do modelo com  $T = 0,50$  aplicado a todo o teste.

Os cortes escolhidos na validação se sustentaram no teste: a cobertura passou de 89,22% para 87,83%, o FN de 1,24% para 1,72%, o FP de 0,85% para 0,56% e o erro automático de 1,18% para 1,32%. Como  $T = 0,50$  está dentro da faixa manual, a política também reorganiza os erros do modelo: dos 43 falsos negativos e 28 falsos positivos de  $T = 0,50$ , só 13 e 4, respectivamente, ficam em decisões automáticas, e os outros 54 caem na análise manual, onde podem ser revistos. A faixa manual concentra a incerteza: 91 de phishing e 87 legítimos (51,12% e 48,88%), quase empatados.

A limitação da política é que a faixa negativa automática não é perfeitamente segura. Na faixa de probabilidade abaixo de 10%, 13 sites (2,06% da faixa) são phishing real, e eles correspondem aos 1,72% dos phishing liberados sem revisão. Para uma aplicação de segurança isso pode ser inaceitável, dependendo da tolerância a risco da operação. Um  $t1$  menor poderia ser testado com faixas mais estreitas, já que o programa permite configurar a largura. Isso reduziria a cobertura sem eliminar o risco, e a faixa manual, mesmo pequena, tem o papel de reter os casos ambíguos.

## 6. CONCLUSÃO

Este trabalho construiu e avaliou modelos de classificação binária em três domínios (análise de sentimentos em avaliações, aprovação de anúncios de fazenda e detecção de sites de phishing) e desenvolveu um programa reutilizável que usa histogramas das probabilidades estimadas para definir faixas de decisão: negativo automático, análise manual e positivo automático. Em todos os domínios, as transformações foram ajustadas apenas no treino, os modelos foram selecionados por validação cruzada estratificada de 5 partições e os pontos de corte foram escolhidos com probabilidades fora da amostra do conjunto de desenvolvimento, deixando o teste para a avaliação final.

Em sentimentos, a base balanceada e o custo baixo e parecido dos dois erros levaram ao F1 como métrica-alvo. O Naive Bayes Multinomial com TF-IDF foi selecionado e obteve, no teste, acurácia e F1 de 0,8213 e AUC-ROC de 0,8958. A Regressão Logística teve desempenho equivalente (diferença de 3 frases em 750), de modo que a ordem entre os dois pode mudar entre validação e teste sem indicar erro de método. Em Farm Ads, também com F1 como métrica-alvo, o Random Forest foi selecionado, com F1 de 0,9047, recall de 0,9439 e AUC-ROC de 0,9696, praticamente empatado com a Regressão Logística (F1 de 0,9041). Em phishing, o custo maior do falso negativo justificou o recall como métrica-alvo. O Gradient Boosting, treinado após a remoção de 5.206 linhas duplicadas, teve o melhor desempenho entre os domínios: acurácia de 0,9515, recall de 0,9430 e AUC-ROC de 0,9924. O SHAP mostrou explicações coerentes: termos como great e excellent

empurram para positivo e not e poor para negativo, e URL\_of\_Anchor e SSLfinal\_State foram os atributos mais determinantes em phishing.

As faixas de decisão reduziram o erro em relação ao modelo aplicado a todas as instâncias com  $T = 0,50$ . Em sentimentos ( $t_1 = 30\%$ ,  $t_2 = 70\%$ ), as decisões automáticas cobriram 42,1% do teste com 4,7% de erro, contra cerca de 17,9% sem faixa de análise manual. Em Farm Ads ( $t_1 = 20\%$ ,  $t_2 = 80\%$ ), a cobertura foi de 35,5% com 4,1% de erro, contra 10,6%. Em phishing ( $t_1 = 10\%$ ,  $t_2 = 90\%$ ), a cobertura foi de 87,8% com 1,3% de erro, contra 4,9%. A separação entre as classes explica a diferença: em phishing as probabilidades se concentram nos extremos, enquanto em sentimentos e Farm Ads ficam em boa parte na região intermediária, e 57,9% e 64,5% das instâncias, respectivamente, seguem para análise manual. A métrica-alvo escolhe o modelo, e os pontos de corte decidem como usá-lo, por isso devem ser calibrados à distribuição de probabilidades e ao custo de erro de cada domínio.

Como limitações, as diferenças entre os melhores modelos em sentimentos e Farm Ads são pequenas, o modelo de sentimentos, baseado em unigramas, não captura o escopo da negação, o volume de análise manual é alto nesses dois domínios em phishing, 13 sites de phishing (1,7% do total no teste) são liberados automaticamente, o que pode ser inaceitável conforme a tolerância a risco e não é possível saber se as duplicatas removidas eram o mesmo site ou sites distintos com o mesmo perfil de atributos. Ainda assim, a separação rigorosa entre treino, validação e teste e a escolha dos cortes apenas com dados de desenvolvimento dão uma ideia realista do desempenho em dados novos, e o programa de faixas se mostrou uma ferramenta reutilizável para equilibrar automação e revisão manual.

## 7. REFERÊNCIAS

KOTZIAS, D. **Sentiment Labelled Sentences**. UCI Machine Learning Repository, 2015.

DOI: 10.24432/C57604. Disponível em:

<https://archive.ics.uci.edu/dataset/331/sentiment+labelled+sentences>. Acesso em: 23 set. 2026.

MESTERHARM, C.; PAZZANI, M. **Farm Ads**. UCI Machine Learning Repository, 2011. DOI:

10.24432/C5ZC8D. Disponível em: <https://archive.ics.uci.edu/dataset/218/farm+ads>. Acesso em: 29 set. 2026.

MOHAMMAD, R.; MCCLUSKEY, L. **Phishing Websites**. UCI Machine Learning Repository,

2012. DOI: 10.24432/C51W2X. Disponível em:

<https://archive.ics.uci.edu/dataset/327/phishing+websites>. Acesso em: 23 set. 2026.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In:

ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017, Long

Beach, CA. **Anais eletrônicos [...]**. [S. l.]: Neural Information Processing Systems

Foundation, 2017. p. 4765-4774. Disponível em:

<https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abs tract.html>. Acesso em: 25 set. 2026.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 26 set. 2026.